

LAPORAN TEKNIS DATA SCIENCE

PELET (Pencari Lowongan Efektif & Tepat): AI Semantic Matching Berbasis SKKNI Coding Camp 2026 powered by DBS Foundation

ID Tim: CC26-PSU060

Disusun oleh:

Sukma Novianti Tulak (CDCC237D6X1337) - Data Scientist

Ai Irma Anjelina (CDCC237D6X1441) - Data Scientist

BAB 1 PROBLEM DISCOVERY

1.1 Latar Belakang

Indonesia menghadapi masalah ketidakcocokan kualifikasi (skill mismatch) yang kronis antara kompetensi pencari kerja dan kebutuhan nyata industri. Berdasarkan data Badan Pusat Statistik, tingkat pengangguran terdidik di Indonesia masih tinggi meskipun permintaan tenaga kerja di sektor teknologi terus meningkat. Fenomena ini menunjukkan adanya celah struktural antara apa yang dipelajari pencari kerja dengan apa yang dibutuhkan industri.

Sistem pencocokan kerja konvensional yang ada di pasar masih sangat bergantung pada keyword matching yang kaku. Sistem tersebut belum mengenali hubungan semantik antar skill, misalnya tidak mengenali bahwa "React" berkorelasi erat dengan "Front-End Development", atau bahwa "machine learning" adalah padanan konseptual dari "pembelajaran mesin" dalam konteks SKKNI.

Di sisi lain, Indonesia memiliki dokumen acuan Standar Kompetensi Kerja Nasional Indonesia (SKKNI) yang seharusnya menjadi standar terukur untuk menilai kompetensi tenaga kerja. Namun standar ini belum terintegrasi secara cerdas dengan sistem rekrutmen berbasis AI yang ada saat ini.

1.2 Identifikasi Masalah

Berdasarkan eksplorasi awal terhadap empat core dataset proyek, tim Data Science menemukan tiga permasalahan utama.

- Kesenjangan Standar Kompetensi (Kamus Global vs Nasional)
Dari 114 skill internasional terpopuler yang diekstrak dari resume dan lowongan kerja, belum ada yang dipetakan secara resmi ke unit kompetensi SKKNI. Seluruh baris status pada berkas awal [skill_mapping_dictionary.csv](#) bernilai "*Belum Dipetakan*".
- Keterbatasan Informasi Pasar Kerja (*Sparsity Data*)
Dari 2.516 lowongan kerja aktif di Indonesia, sebanyak 88,1% tidak mencantumkan tingkat jabatan (*job level*) dan 80,5% menyembunyikan informasi gaji. Hal ini menciptakan asimetri informasi yang menyulitkan pencari kerja.
- Ketidakseimbangan Struktural SKKNI
Dokumen SKKNI memiliki 662 unit kompetensi, namun hanya mencakup sekitar 40 dari 194 jabatan unik yang dibutuhkan industri digital saat ini. Jabatan mutakhir seperti *DevOps Engineer*, *Data Scientist*, dan *AI Engineer* belum terakomodasi sepenuhnya secara eksplisit.

1.3 Pertanyaan Bisnis

Berdasarkan latar belakang proyek pengembangan sistem PELET (Pencari Lowongan Efektif & Tepat), analisis data dilakukan untuk menjawab tiga pertanyaan bisnis utama berikut:

- Bagaimana kesenjangan (gap) antara rumpun skill digital yang dimiliki oleh para pelamar kerja dengan kualifikasi skill yang saat ini paling banyak dibutuhkan oleh industri?
- Bagaimana kecocokan profil pengalaman kerja (tahun pengalaman) para pencari kerja saat ini jika disandingkan dengan ekspektasi atau persyaratan minimum dari industri?
- Seberapa luas cakupan atau kesesuaian unit kompetensi standar nasional (SKKNI) dalam memetakan skill-skill digital modern yang berkembang di pasar kerja saat ini?

1.4 Solusi yang Diusulkan

Tim Data Science mengusulkan pembangunan *pipeline* analitik *end-to-end* dengan dua output utama:

- Interactive Dashboard Analytics

Menggunakan Streamlit untuk menyajikan visualisasi dinamis mengenai tren lowongan kerja, sebaran geografis, analisis *experience bucket*, dan peta analisis kesenjangan (*gap analysis*) SKKNI.

- Scientific Validation via A/B Testing

Melakukan eksperimen komparatif untuk membuktikan keunggulan model *Sentence-BERT Multilingual* dibandingkan metode konvensional (TF-IDF), yang nantinya diimplementasikan sebagai *core matching engine* pada sistem utama Pelet.

DATA WRANGLING

2.1 Gathering Data

Pada tahap awal, tim Data Science mengumpulkan dataset mentah (*raw data*) dari berbagai sumber eksternal (Kaggle, Portal Resmi SKKNI, dan GitHub) yang relevan dengan ruang lingkup proyek Pelet.

- Dataset Profil Pelamar dan Keahlian Industri (Sumber: Kaggle)

Kami mengunduh beberapa dataset mentah utama dari platform Kaggle, yaitu [training_data.csv](#) berisi 10.000 data resume profil pelamar kerja hasil generator sintetis. Teks resume di dalamnya masih dipenuhi karakter non-alfabet, *stop-words*, dan daftar skill yang tersimpan dalam format string panjang dan skills list.csv yang memuat daftar referensi hubungan keahlian industri. Kondisi awal kedua dataset ini masih sangat kotor dan tidak terstruktur; teks di dalamnya berupa *string* panjang bising yang dipenuhi karakter non-alfabet, banyak baris data yang duplikat, serta penulisan istilah keahlian yang formatnya tidak seragam dan masih bercampur antara bahasa Inggris dan Indonesia. Link data: [Dataset 1](#), [Dataset 2](#)

- Indonesia Job Vacancy Dataset (Kondisi Awal Mentah/Raw Data dari GitHub)
- Merupakan data lowongan kerja yang bersumber dari repositori GitHub. Kondisi awal dataset ini memiliki format teks pada kolom persyaratan (requirement), deskripsi pekerjaan (description), dan judul posisi (title) yang sangat kotor (memiliki karakter non-standar, huruf kapital tidak beraturan, serta *missing values* pada informasi gaji dan ukuran perusahaan).

Link : [Dataset-Job](#)

- Dokumen Standar Kompetensi Kerja Nasional (Sumber: Portal Resmi SKKNI)

Data ini diperoleh melalui proses *scraping* manual dan unduhan langsung dari situs resmi Standar Kompetensi Kerja Nasional Indonesia (SKKNI). Dokumen yang didapatkan berupa kumpulan file PDF kaku berisi teks narasi hukum dan format tabel administratif pemerintah. Kondisi awal data ini sangat mentah karena ribuan kode unik dan deskripsi unit kompetensi resmi masih menyatu dalam satu blok teks besar yang belum diparsing sama sekali ke dalam format basis data.

2.2 Assessing Data

Setelah mengumpulkan data mentah, tim Data Science melakukan pemeriksaan kualitas data (*data assessment*) untuk mengidentifikasi keberadaan *missing values*, *duplicate rows*, serta *inconsistent values*. Melalui proses ini, ditemukan beberapa masalah kualitas pada masing-masing dataset.

- Isu Kualitas Data pada Dataset Job (Github)
 - *Missing Values* (Data Kosong): Terdapat banyak kekosongan data intrinsik (*inherent sparsity*) pada kolom finansial dan klasifikasi industri, seperti kolom informasi gaji (*min_salary* dan *max_salary*) serta kolom batas ukuran perusahaan (*min_company_size* dan *max_company_size*) yang bernilai 0 atau None. Kolom tipe kerja (*type_of_work*) dan kualifikasi (*qualification*) juga memiliki nilai *Missing*.
 - Inkoneksitas String/Teks: Data teks pada kolom *title*, *requirement*, dan *description* ditulis secara tidak seragam, mengandung tanda baca berlebih, *whitespace* berlipat ganda, serta percampuran bahasa (Inggris-Indonesia).
- Isu Kualitas Data pada Dataset SKKNI
 - Duplikasi dan Redundansi Data: Terdapat baris data duplikat akibat pengulangan kode unit dan judul unit karena satu unit kompetensi dapat memiliki beberapa elemen kompetensi dan target jabatan yang dijabarkan per baris.
 - Kotoran Teks: Adanya *unnecessary whitespace* di awal/akhir string teks pada kolom Elemen Kompetensi dan Jabatan.
- Isu Data pada dataset training ([cleaned_training_data.csv](#))
 - Kolom keahlian (*skills_clean*) pada data resume tersimpan sebagai tipe data tulisan teks biasa (string).
 - Pada file [skill_mapping_dictionary.csv](#), kolom status Kecocokan dan Kode_Unit_SKKNI seluruhnya kosong.
- Isu Kualitas Data pada Dataset Referensi Keahlian ([skills_list.csv](#))
 - Redundansi Nama Keahlian (Duplicate Rows): Ditemukan banyak sekali duplikasi entitas keahlian di dalam data. Satu jenis keahlian yang sama muncul beberapa kali di baris yang berbeda karena perbedaan kecil pada ID entitasnya.

- Ketidakteraturan Penulisan (Inconsistent Values): Penulisan nama-nama keahlian teknis masih sangat berantakan dan tidak standar. Terdapat variasi penulisan untuk teknologi yang sama (misalnya penulisan huruf besar-kecil seperti "python", "Python", dan "PYTHON"), serta adanya kesalahan ketik (*typo*) pada beberapa istilah teknologi industri.

2.3 Cleaning Data

Berdasarkan hasil pemeriksaan kualitas data (*data assessment*), tim Data Science melakukan proses pembersihan data (*data cleaning*) secara terprogram untuk memastikan seluruh dataset siap digunakan dalam proses pemodelan AI.

- Dataset Lowongan Kerja Indonesia (Sumber: GitHub / [cleaned_job_5.csv](#))
 - Pembersihan Teks (Text Cleansing): Melakukan normalisasi string pada kolom title, requirement, dan description menggunakan *Regular Expression* (re). Langkahnya meliputi mengubah teks menjadi huruf kecil seluruhnya (*case folding*), menghapus karakter non-alfabet/symbol, menghilangkan *whitespace* berlebih, serta membersihkan teks HTML sisa dari format web asal.
 - Penanganan Missing Values: * Kolom kategori/teks yang kosong seperti *type_of_work* dan *qualification* diubah nilainya menjadi string "None" atau "Tidak Diketahui".
 - Kolom numerik gaji (*min_salary*, *max_salary*) dan ukuran perusahaan yang kosong dipertahankan secara konsisten menggunakan nilai penanda standar (0 atau "None") agar tidak merusak distribusi data asli saat dilakukan filter analisis.
 - Standardisasi Waktu: Kolom time dibersihkan dan diseragamkan format penulisan tanggalnya agar siap dianalisis berdasarkan runtun waktu lowongan dibuka.
- Dataset Profil Pelamar (Sumber: Kaggle / [training_data.csv](#))

Eliminasi Polusi Teks: Menghapus seluruh karakter non-alfabet seperti simbol-simbol aneh dan tanda baca pembentuk *bullet points* tiruan yang mengotori teks resume pelamar. Tim juga melakukan penghapusan kata umum yang tidak bermakna (*stop-words removal*).

Strukturisasi Kolom Keahlian: Mengonversi data pada kolom keahlian (skills) yang awalnya berupa tulisan teks biasa (*string* panjang tak terstruktur) menjadi bentuk token kata yang bersih, seragam, dan siap dipetakan oleh model NLP.

- Dataset Referensi Keahlian (Sumber: Kaggle / [skills list.csv](#))

Normalisasi dan Standardisasi Teks: Mengatasi masalah ketidakseragaman penulisan (*inconsistent values*) dengan menerapkan *case folding* ke huruf kecil seluruhnya. Langkah ini berhasil menyatukan variasi penulisan teknologi yang sama (seperti "python", "Python", dan "PYTHON" menjadi satu entitas "python"). Teks yang mengandung kesalahan ketik (*typo*) juga diperbaiki secara massal.

Pembersihan Baris Duplikat (*Drop Duplicates*): Menghapus baris data yang terduplikasi akibat perbedaan kecil pada ID entitasnya, sehingga setiap nama keahlian teknis hanya memiliki satu baris entitas yang unik dan bersih.

- Dokumen Standar Kompetensi Kerja (SKKNI ([skkni_reference_clean.csv](#)):

Pembersihan Spasi (*Stripping Whitespace*): Menghapus spasi tidak berguna di awal dan di akhir string pada setiap kolom teks (Kode Unit, Judul Unit, Elemen Kompetensi, Jabatan) agar proses pencocokan kata (*string matching*) di tahap pemodelan menjadi akurat.

Drop Duplicates: Membuang baris data yang terduplikasi secara penuh (persis sama di seluruh kolom) untuk memastikan keunikan relasi kompetensi dan mengoptimalkan memori data sewaktu diekspor menjadi [skkni_reference_clean.csv](#).

BAB 3

EXPLORATORY DATA ANALYSIS (EDA) DAN DATA DICTIONARY

3.1 EDA - AWAL

Fase ini bertujuan untuk mengeksplorasi kesiapan data setelah fase pembersihan, sekaligus melakukan penyelarasan bahasa (*alignment*) antara kompetensi praktis pada resume dengan standardisasi formal nasional. Pada EDA awal menggunakan 3 dataset [cleaned_training_data.csv](#), [cleaned_skills_list.csv](#), [data_pekerjaan.csv](#).

- Analisis Sisi Supply (Kandidat Resume)
 - Kepadatan Keahlian Kandidat: Berdasarkan ekstraksi data resume pada `df_resume`, setiap kandidat memiliki daftar keahlian bersih (`skills_clean_list`) yang ditarik dari dokumen resumanya. Distribusi frekuensi ini menunjukkan keragaman kompetensi siap pakai yang ditawarkan oleh pasokan talenta di pasar kerja.
 - Dominasi Hard-Skill pada Pasokan: Hasil visualisasi *Top 10 Skill pada Resume Pelamar* mengonfirmasi adanya pemusatan yang kuat pada keahlian teknis berbasis data (*hard skills*). Kompetensi bahasa pemrograman seperti Python dan kueri basis data seperti SQL menempati peringkat tertinggi dengan frekuensi kemunculan paling masif di sisi kandidat.
- Analisis Sisi Demand (Pasar Kompetensi Regulasi SKKNI)
 - Standardisasi Kompetensi Industri: Analisis terhadap dataset pekerjaan (`df_skjni`) dilakukan dengan mengukur frekuensi kemunculan 'Judul Unit' kompetensi. Hal ini merepresentasikan struktur kebutuhan baku dari sisi regulasi nasional (SKKNI) dan pemetaan standar kompetensi kerja yang dituntut oleh industri.
 - Unit Kompetensi Terpopuler: Grafik *Top 10 Unit Kompetensi SKKNI* menunjukkan adanya beberapa unit acuan yang paling sering dirujuk dan disyaratkan. Konsentrasi tinggi pada judul-judul unit tertentu mengindikasikan area kompetensi yang paling kritikal dan wajib dipenuhi dalam ekosistem tenaga kerja saat ini.

- Analisis Output Dataset Hasil Pemetaan (Fase Kolaborasi)

Struktur Kamus Pemetaan Skill Kerja: Dataset pertama yang diekspor, [skill_mapping_dictionary.csv](#), merupakan hasil integrasi langsung antara pasokan keahlian (*supply*) dan kebutuhan standar (*demand*). Kamus ini berfungsi menjembatani kesenjangan (*gap*) bahasa antara istilah keahlian praktis di resume kandidat dengan bahasa kompetensi formal yang diakui regulasi.

Standardisasi Dokumen Referensi Jabatan: Dataset kedua, [skkni_reference_clean.csv](#), menyajikan struktur data referensi SKKNI yang bersih setelah melalui proses penghapusan duplikasi data (*drop_duplicates*). Data ini secara terstruktur merangkum fitur-fitur penting seperti Kode Unit, Judul Unit, Elemen Kompetensi, hingga Jabatan terkait, yang menjamin keandalan basis data untuk pengujian model pencocokan karir (*career matching*) yang presisi.

3.2 EDA - Final

EDA Final mengeksplorasi kondisi pasar kerja secara komprehensif menggunakan 4 dataset final [skill_mapping_dictionary.csv](#), [skkni_reference_clean.csv](#), [cleaned_job_5.csv](#), [cleaned_training_data.csv](#). Melalui analisis ini, hubungan timbal balik antara industri (Lowongan Kerja) dan pencari kerja (Resume) dibedah secara makro.

- Analisis Sisi Supply (Kandidat Resume)

Dominasi Kluster Industri: Sektor Technology menguasai porsi pasokan terbesar dengan akumulasi 2.511 resume (25,1%), disusul oleh rumpun Finance (12,0%) dan Healthcare (9,8%). Hal ini menjamin reliabilitas data untuk kebutuhan pengujian model digital pencocokan karir SkillBridge AI.

Kepadatan Keahlian Kandidat: Rata-rata pelamar mengklaim memiliki 8,3 jenis keahlian di dalam dokumen resumenya. Distribusi data berbentuk kurva normal skewness positif lemah.

Fenomena Soft-Skill Bias: Berdasarkan visualisasi frekuensi kata kunci keahlian teratas, soft skills universal menempati peringkat tertinggi: communication (4.821 kemunculan) dan problem solving (4.103 kemunculan). Pada kategori keahlian teknis (hard skills),

bahasa pemrograman SQL (3.201) dan Python (2.287) memimpin pasar pasokan kandidat.

- Analisis Sisi Demand (Pasar Lowongan Kerja)

Sentralisasi Geografis Korporasi: Pasar lowongan kerja di Indonesia mencatat tingkat pemusatan wilayah yang sangat timpang. Jakarta mendominasi sebesar 73,4% (1.847 lowongan), menempatkan wilayah pertumbuhan lain seperti Bandung (189 lowongan) dan Surabaya (124 lowongan) jauh di belakang.

Struktur Gaji Teknis: Melalui penyaringan fitur `has_salary`, nilai tengah (median) upah bulanan untuk profesional di sektor ini menyentuh angka Rp 8,5 Juta. Rentang sebaran bernilai sangat lebar (antara Rp 2 Juta hingga Rp 150 Juta per bulan), mengonfirmasi tingginya kompensasi untuk tingkat keahlian spesifik (Senior/Expert architecture).

Posisi Terpopuler Korporasi: Kebutuhan rekrutmen industri tertinggi ditargetkan pada posisi Business Development Manager (143 lowongan), diikuti oleh posisi Data Analyst (127 lowongan) dan Fullstack Developer (98 lowongan).

- Analisis Dokumen Regulasi SKKNI

Ketimpangan Beban Kompetensi: Hasil agregasi volume unit kompetensi memperlihatkan profesi Programmer memikul beban standardisasi paling kompleks dengan total 37 unit kompetensi. Rumpun Keuangan menempati posisi kedua dengan 28 unit, diikuti Cyber Security dengan 25 unit kompetensi resmi.

3.3 Data Dictionary

Tabel 1: [skkni_reference_clean.csv](#)

Kolom	Tipe	Deskripsi	Contoh
Kode Unit	string	Kode unik unit kompetensi SKKNI	C.29TDI01.001.1
Judul Unit	string	Nama/judul unit kompetensi	Merumuskan Aspirasi Transformasi Industri 4.0
Elemen Kompetensi	string	Sub-elemen dari unit kompetensi	Mengenali industri 4.0
Jabatan	string	Jabatan yang memiliki unit ini	Manager

Tabel 2: [skill_mapping_dictionary.csv](#)

Kolom	Tipe	Deskripsi	Contoh
Skill_Internasional_Kaggle	string	Nama skill dalam bahasa Inggris	python
Kode_Unit_SKKNI	string	Kode unit SKKNI yang sesuai (kosong)	NaN
Judul_Unit_SKKNI	string	Judul unit SKKNI yang sesuai (kosong)	NaN
Kecocokan	string	Status pemetaan	Belum Dipetakan

Tabel 3: [cleaned_training_data.csv](#)

Kolom	Tipe	Deskripsi	Contoh
Resume ID	string	ID unik resume	R000000
Resume Text	string	Teks resume lengkap	Education: Bachelor's...
Education	string	Latar belakang pendidikan	Bachelor's in Computer Science
Experience Years	int	Lama pengalaman kerja (tahun)	2
Skills	string	Daftar skill dipisah pipe	Java REST API SQL
Job Role	string	Jabatan/peran pekerjaan	Java Backend Developer
Category	string	Kategori bidang pekerjaan	Technology
resume_text_clean	string	Teks resume setelah cleaning	education bachelor s...
skills_clean	string	Skill dalam format list Python	['java', 'sql', 'rest api']

Tabel 4: [cleaned_job_5.csv](#)

Kolom	Tipe Data	Deskripsi	Contoh
logo	string	URL tautan gambar logo perusahaan	https://images.glints.com/...
title	string	Judul posisi lowongan pekerjaan (sudah bersih/huruf kecil)	business development manager it cyber security
company	string	Nama perusahaan yang membuka lowongan pekerjaan	Nawatech
location	string	Lokasi atau wilayah penempatan kerja perusahaan	Jakarta
min_company_size	int	Batas minimum ukuran total karyawan di perusahaan tersebut	0
max_company_size	int	Batas maksimum ukuran total karyawan di perusahaan tersebut	0
type_of_work	string	Jenis ikatan kontrak kerja (Full Time, Part Time, dll) atau "None" jika kosong	Penuh Waktu
requirement	string	Teks prasyarat kemampuan, keahlian, atau kompetensi yang dicari	business development sales skills sales hunting...
job_level	string	Tingkat senioritas jabatan posisi yang ditawarkan di perusahaan	Pemula / Staf
description	string	Deskripsi tugas, tanggung jawab, dan detail fungsi pekerjaan	deskripsi pekerjaan business development manager...
min_work_experience	int	Batas minimum pengalaman kerja yang diminta oleh perusahaan (tahun)	1
max_work_experience	int	Batas maksimum pengalaman kerja yang diminta oleh perusahaan (tahun)	3
qualification	string	Syarat kelulusan latar belakang pendidikan minimal	Sarjana/S1
currency	string	Mata uang yang digunakan untuk acuan nominal penggajian	IDR
min_salary	float	Batas nilai gaji minimal yang ditawarkan oleh perusahaan	8000000.0

max_salary	float	Batas nilai gaji maksimal yang ditawarkan oleh perusahaan	15000000.0
time	string	Waktu atau tanggal rilis informasi lowongan pekerjaan diunggah	29/12/2022 13:47:30
link	string	URL tautan langsung menuju halaman detail lowongan kerja asli	https://www.karir.com/opportunities/...

BAB 4

EXPLANATORY ANALYSIS & VISUALISASI

Berfokus pada hasil eksplorasi visual dan analisis eksplanatoris (*explanatory analysis*) guna menjawab tiga pertanyaan bisnis inti. Analisis ini menjembatani bias informasi makro ke bentuk narasi data taktis yang mendasari arsitektur pencocokan karir pada sistem.


4.1 Pertanyaan Bisnis 1: Kesenjangan Rumpun Keahlian (Skill Gap Analysis)

Rumusan Masalah: *Bagaimana kesenjangan (gap) antara rumpun skill digital yang dimiliki oleh para pelamar kerja dengan kualifikasi skill yang saat ini paling banyak dibutuhkan oleh industri?*

Melalui ekstraksi token data menggunakan metode penstrukturan berbasis kamus korpus, ditemukan ketidakseimbangan struktural yang masif antara kompetensi pasokan (*supply*) dari resume pelamar dengan kebutuhan (*demand*) spesifik dari bursa kerja industri:

- Defisit Kompetensi Teknis (Under-Supply): Industri mencatat permintaan yang sangat tinggi untuk keahlian rekayasa berbasis web dan basis data seperti PHP (Gap: +222.5), MySQL (Gap: +159.3), dan JavaScript (Gap: +146.6). Namun, ketersediaan keahlian ini pada resume pelamar sangat minim, yang memicu tingginya durasi pemenuhan posisi lowongan (*time-to-hire*).
- Saturasi Klaim Soft Skills (Over-Supply): Pelamar secara masif mencantumkan klaim deskriptif umum pada resume mereka, dengan dominasi pada Communication (Supply: 437.4) dan Problem Solving (Supply: 421.6). Sebaliknya, korporasi jarang mencantumkan indikator ini secara eksplisit pada teks lowongan kerja karena lebih berfokus pada syarat kecakapan teknis keras (*hard skills*).
- Insight Utama Sistem: Kondisi ini membuktikan secara empiris bahwa proses pencocokan kerja (*job matching*) tidak bisa hanya mengandalkan pendekatan pencarian kata kunci biasa atau pembobotan frekuensi teks linier standar seperti TF-IDF dasar. Diperlukan pendekatan berbasis pemetaan semantik (*semantic mapping*) mendalam yang diadopsi oleh sistem.

Hasil Visualisasi :



4.2 Pertanyaan Bisnis 2: Profil Pengalaman Kerja vs Ekspektasi Industri

Rumusan Masalah: *Bagaimana kecocokan profil pengalaman kerja (tahun pengalaman) para pencari kerja saat ini jika disandingkan dengan ekspektasi atau persyaratan minimum dari industri?*

Melalui pengelompokan (*binning*) data pengalaman kerja ke dalam 5 kluster standar industri (*Fresh Graduate, Junior, Mid, Senior, Expert*), pengujian statistik deskriptif menemukan pola ketidaksesuaian vertikal (*vertical mismatch*):


- Saturasi Tingkat Junior: Pelamar pada kategori Junior (1–3 tahun) merupakan kelompok dengan volume sebaran data paling padat dan dominan pada dataset pelamar aktif.
- Tingginya Ambang Batas Industri: Kebutuhan rekrutmen perusahaan terkonsentrasi secara solid pada level Senior (5–10 tahun) untuk memegang kendali sistem arsitektur teknis yang kompleks.

Fenomena ini mengonfirmasi adanya penumpukan pelamar junior yang terpaksa berkompetisi pada formasi lowongan kerja yang sebenarnya memerlukan kualifikasi keahlian teknis serta jam terbang manajerial yang lebih matang.

Rekomendasi Strategis: Temuan ini memperkuat urgensi modul Analisis Kesenjangan Kompetensi (*Skill Gap Analysis*) pada platform. Sistem dirancang untuk memberikan

umpan balik (*feedback loop*) otomatis kepada talenta junior mengenai peta keahlian taktis yang wajib mereka tingkatan agar mampu memenuhi kualifikasi level karir di atasnya.

Hasil visualisasi :



4.3 Pertanyaan Bisnis 3: Cakupan & Relevansi Dokumen Regulasi SKKNI

Rumusan Masalah: *Seberapa luas cakupan atau kesesuaian unit kompetensi standar nasional (SKKNI) dalam memetakan skill-skill digital modern yang berkembang di pasar kerja saat ini?*


Integrasi database dilakukan dengan menyandingkan kamus pemetaan skill internasional (*skill dictionary*) terhadap 5 rumpun jabatan prioritas nasional, yaitu *Programmer*, *Data Analyst*, *Data Scientist*, *Cyber Security*, dan *Keuangan*. Analisis eksplanatori menghasilkan poin-poin kesimpulan berikut:

- Representasi Kompetensi Inti: Lima rumpun jabatan utama yang diuji berhasil mencakup sebanyak 133 unit kompetensi SKKNI resmi lengkap dengan ratusan elemen kriteria unjuk kerja pendukung.
- Kekuatan Sektor Konvensional: Sub-sektor Programmer/Software Developer serta kluster Keuangan mencatat tingkat pemetaan (*coverage rate*) paling komprehensif, matang, dan terstruktur dengan baik.
- Kebutuhan Pembaruan Kontemporer: Meskipun dinilai sangat representatif sebagai jangkar pemetaan semantik berbasis aturan regulasi nasional, terdapat beberapa terminologi teknologi mutakhir seperti framework AI terapan dan arsitektur spesifik

Multi-Cloud modern yang belum terakomodasi secara eksplisit dalam unit SKKNI formal.

Secara keseluruhan, kuantitas unit kompetensi ini terbukti valid dan memadai untuk digunakan sebagai basis data relasional (*ground truth*) dalam proses pencocokan semantik. Penyempurnaan dan perluasan cakupan kamus kompetensi secara bertahap direkomendasikan agar platform dapat adaptif terhadap akselerasi teknologi global di masa depan.

Hasil visualisasi:



4.4. Kesimpulan Visualisasi

Berdasarkan hasil analisis data komprehensif terhadap sisi *Supply* (Resume), *Demand* (Lowongan Kerja), dan Regulasi (SKKNI), dapat disimpulkan tiga poin utama:


- Adanya *Structural Mismatch* di Pasar Kerja Digital
 - Kesenjangan Keahlian (*Skill Gap*): Terjadi defisit pasokan pada *hard skills* teknis yang sangat dibutuhkan industri (seperti PHP, MySQL, JavaScript). Sebaliknya, terjadi penumpukan (*over-supply*) klaim *soft skills* generik (seperti *Communication* dan *Problem Solving*) di sisi pelamar.
 - Kesenjangan Pengalaman (*Vertical Mismatch*): Mayoritas pencari kerja berada di level *Junior* (1–3 tahun pengalaman), sedangkan lowongan yang tersedia didominasi oleh kualifikasi tingkat *Senior* (5–10 tahun pengalaman).
- Kesiapan Regulasi SKKNI sebagai Kompas Industri Standardisasi nasional melalui SKKNI telah mencakup fondasi yang kuat dengan 133 unit kompetensi utama pada 5 rumpun jabatan digital prioritas. Namun, diperlukan pembaruan berkala kamus

kompetensi adaptif agar mampu mengimbangi kemunculan tren teknologi baru seperti *AI framework* dan arsitektur *Cloud* yang berkembang dinamis di pasar kerja.

- Urgensi Implementasi Solusi pelet Metode pencocokan kerja konvensional berbasis kata kunci linier seperti TF-IDF dasar terbukti tidak lagi memadai untuk menangani ketimpangan ini. Solusi berbasis Pencocokan Semantik (*Semantic Matching*) dan fitur Analisis Kesenjangan Kompetensi (*Skill Gap Analysis*) pada platform SkillBridge AI menjadi sangat mendesak untuk memitigasi bias informasi serta membantu talenta junior meningkatkan keahliannya sesuai ekspektasi riil industri.

Hasil Visualisasi :

Ringkasan EDA — Dataset PELET CC26-PSU060



BAB 5

DASHBOARD STREAMLIT

5.1 Arsitektur Dashboard

Aplikasi antarmuka dashboard dibangun menggunakan kerangka Streamlit berstruktur modular yang mengonsumsi data secara efisien melalui mekanisme optimalisasi memori `@st.cache_data` langsung pada layer antarmuka `dashboard.py`. Langkah ini memastikan bahwa fungsi pemuatan data dari `data_loader.py` tidak dieksekusi berulang kali setiap ada interaksi pengguna pada komponen widget. Aplikasi ini dirancang untuk menyajikan wawasan komprehensif dari hasil pemrosesan data dan dibagi ke dalam empat bilah halaman interaktif:

- Halaman Overview (Ringkasan Proyek): Menyajikan kartu metrik kinerja utama (Key Performance Indicator - KPI) secara makro yang mencakup total volume lowongan kerja (2.516 entri), total resume pelamar (10.000 entri), total unit kompetensi SKKNI (662 unit), serta persentase ketercakupan awal (coverage rate) secara agregat. Halaman ini juga dilengkapi dengan narasi visual pengantar proyek kelompok serta visualisasi distribusi kategori resume dan jabatan SKKNI menggunakan diagram batang horizontal.
- Halaman Job Market (Analisis Pasar Kerja): Menyediakan fitur penapis (filter) interaktif multi-variabel berbasis pilihan Kota, Tipe Kerja, dan Mata Uang Gaji. Halaman ini membedah pasar kerja lewat visualisasi top kota, proporsi tipe pekerjaan menggunakan *pie chart*, histogram distribusi titik tengah gaji (salary mid) dalam rupiah, grafik kotak (*box plot*) batasan pengalaman, serta perbandingan *mismatch* pengalaman kerja antara pasokan tenaga kerja (*supply*) dan kebutuhan industri (*demand*).
- Halaman Skill Demand (Analisis Kebutuhan Keahlian): Menyajikan visualisasi komparatif interaktif yang membagi analisis ke dalam tiga tab, yaitu analisis berbasis resume, analisis kebutuhan spesifik industri (*requirement* lowongan) yang diekstrak menggunakan metode pencocokan ekspresi reguler (*regex matching*), serta tab perbandingan langsung frekuensi *skill* yang telah dinormalisasi per 1.000 entri untuk menjaga keadilan skala komparasi kedua dataset.
- Halaman SKKNI Gap Analysis (Analisis Kesenjangan Standar): Memuat kartu metrik ringkasan status kompetensi, diagram lingkaran (*donut chart*) komposisi sebaran, grafik

batang *skill* yang diserap per jabatan SKKNI, serta tabel detail dinamis interaktif yang dilengkapi pewarnaan visual (*styling*) khusus status pemetaan. Grafik batang komparatif (*stacked bar chart*) pada halaman ini merepresentasikan hasil *domain knowledge enrichment* dan pencocokan data yang membagi status ketercakupan menjadi tiga kategori yaitu : Terpetakan (10.5%), Parsial (4,39%), dan Belum Dipetakan (85.1).

5.2 Dokumentasi Data Enrichment pada Dashboard

Proses pemetaan kompetensi pada dashboard dilakukan dengan menghubungkan *skill* dari dataset lowongan kerja dan resume terhadap standar kompetensi SKKNI. Namun, tidak seluruh *skill* pada dataset dapat terpetakan secara otomatis karena adanya perbedaan penulisan istilah, variasi kata, maupun keterbatasan kecocokan *semantic matching*.

Oleh karena itu, dilakukan proses pemetaan manual (*data enrichment*) menggunakan struktur kamus data internal (MANUAL_MAPPING) di dalam sistem dashboard untuk beberapa *skill* krusial yang belum terakomodasi secara penuh atau masih bersifat parsial di dalam *dictionary* awal seperti bahasa pemrograman Python, Java, Javascript, hingga keahlian *soft skill* seperti *leadership* dan *communication*. Pemetaan manual ini berfungsi sebagai *fallback mechanism* untuk meningkatkan relevansi hasil *matching* secara *real-time*. Langkah ini memastikan dashboard dapat menampilkan hasil analisis *skill gap*, *competency mapping*, dan indikator persentase ketercakupan (*coverage rate*) secara akurat, dinamis, dan representatif terhadap kebutuhan riil industri.

5.3 Tautan Dashboard

Dashboard telah di deploy ke Streamlit Cloud dan dapat diakses secara publik di link berikut:

[Dashboard Streamlit](#)

5.4 Cara Menjalankan Lokal

Untuk menjalankan aplikasi dashboard Streamlit pada lingkungan lokal, eksekusi perintah berikut pada terminal atau command prompt:

```
Shell
pip install -r requirements.txt
streamlit run app.py
```

BAB 6

A/B TESTING

6.1 Desain Eksperimen Lintas Bahasa (Cross-Lingual)

Tantangan utama dalam pengembangan sistem PELET adalah adanya kesenjangan bahasa antar dokumen (*cross-lingual gap*). Berkas lowongan kerja dan resume mayoritas ditulis menggunakan bahasa Inggris teknis, sementara dokumen acuan hukum SKKNI ditulis menggunakan bahasa Indonesia formal baku.

Untuk memvalidasi performa algoritma penjodohan dokumen dalam mengatasi kendala tersebut, Tim Data Science melakukan pengujian eksperimen ilmiah *A/B Testing* dengan menetapkan hipotesis eksperimen sebagai berikut:

- H0: Tidak terdapat peningkatan performa pencocokan dokumen antara penggunaan model *TF-IDF Keyword Matching* dengan model *Sentence-BERT Semantics Matcher*.
- H1: Penggunaan model *Sentence-BERT Multilingual* menghasilkan performa pencocokan rata-rata yang lebih tinggi secara empiris dibandingkan dengan metode *TF-IDF Cosine Similarity Baseline*.

6.2 Konfigurasi Parameter Grup

Eksperimen ini membagi sistem ke dalam dua kelompok pengujian parameter, yaitu:

- Grup A (Baseline Control): Menggunakan representasi berbasis token kata *TF-IDF Cosine Similarity*. Pendekatan ini murni mengandalkan kecocokan kemunculan karakter kosakata fisik secara harfiah dengan batas ambang kemiripan (*threshold*) yang ditentukan sebesar 0.20.
- Grup B (Treatment Variant): Menggunakan arsitektur jaringan saraf berbasis *Sentence-BERT Multilingual* (paraphrase-multilingual-MiniLM-L12-v2). Model ini mentransformasikan teks lintas bahasa ke dalam ruang vektor berdimensi tinggi ($d = 384$) untuk menangkap esensi makna kontekstual tanpa bergantung pada kesamaan kosakata fisik, menggunakan batas ambang kemiripan (*threshold*) sebesar 0.42.

6.3 Metrik Hasil Evaluasi

Evaluasi performa klasifikasi penjodohan dokumen komparatif dilakukan secara menyeluruh menggunakan dataset [cleaned_training_data.csv](#). Berdasarkan eksekusi kode program di dalam *runtime* lingkungan simulasi, metrik utama yang dihasilkan adalah sebagai berikut:

Model Pengujian	Akurasi (Accuracy)	Presisi (Precision)	Recall	F1-Score
Grup A: TF-IDF (Baseline Control)	72,91%	100,00%	45,83%	62,85%
Grup B: Sentence-BERT (Treatment Variant)	76,56%	99,79%	53,23%	69,43%

Studi Kasus Konkret Hasil Prediksi Model: Pada data uji, model TF-IDF (Grup A) sangat bergantung pada kesamaan kosakata fisik (kata kunci). Jika sebuah resume memiliki kecocokan kontekstual yang tinggi terhadap suatu lowongan pekerjaan (misalnya *Java Backend Developer*) namun menggunakan variasi kosakata yang berbeda, TF-IDF cenderung gagal mengenalinya ditandai dengan nilai *Recall* TF-IDF yang rendah, yaitu 45,83%.

Sebaliknya, Sentence-BERT (Grup B) berhasil menangkap kedekatan makna konseptual tersebut secara lebih mendalam (konteks semantik), sehingga mampu menaikkan nilai *Recall* secara signifikan menjadi 53,23% dan mendongkrak F1-Score hingga 69,43%.

6.4 Hasil Uji Signifikansi Statistik

Penentuan model terbaik dalam eksperimen ini didasarkan pada perbandingan metrik evaluasi utama, yaitu F1-Score dan Akurasi. Berdasarkan hasil pengujian:

- Model Sentence-BERT menunjukkan performa yang dominan pada hampir seluruh metrik utama, dengan keunggulan peningkatan Akurasi sebesar +3,65% dan F1-Score sebesar +6,58% secara absolut dibandingkan dengan TF-IDF.
- Nilai presisi (*Precision*) yang tetap terjaga di angka 99,79% menunjukkan bahwa model Sentence-BERT memiliki tingkat kerentanan yang sangat minim terhadap kesalahan deteksi (*false positive*).

Berdasarkan hasil peningkatan empiris tersebut, hipotesis nol (H_0) ditolak dan hipotesis kerja (H_1) diterima. Peningkatan performa ini membuktikan bahwa pendekatan berbasis *semantic*

embedding jauh lebih efektif untuk menangani kebutuhan pencocokan dokumen pada sistem PELET.

Kesimpulan A/B Testing: Model Sentence-BERT secara resmi dipilih sebagai metode utama dalam proses pencocokan resume pada aplikasi PELET karena memiliki performa pemahaman konteks yang jauh lebih baik.

BAB 7

KESIMPULAN DAN LAMPIRAN

7.1 Kesimpulan

Berdasarkan hasil analisis data komprehensif, pengembangan aplikasi dashboard analitik, dan pengujian yang telah dilakukan dalam proyek PELET (Pencari Lowongan Efektif & Tepat), dapat ditarik beberapa kesimpulan utama sebagai berikut:

- **Kesenjangan Rumpun Keahlian (*Skill Gap Analysis*):**
Terdapat ketidakseimbangan struktural yang masif di pasar kerja digital Indonesia. Sisi industri (*demand*) mencatat permintaan yang sangat tinggi pada keahlian teknis keras (*hard skills*) spesifik, seperti rekayasa berbasis web dan basis data PHP dengan nilai kesenjangan +222.5, MySQL +159.3, dan JavaScript +146.6. Sebaliknya, di sisi pelamar (*supply*), terjadi penumpukan (*over-supply*) klaim deskriptif pada kemampuan nonteknis (*soft skills*) universal, seperti *Communication* (4.374 kemunculan) dan *Problem Solving* (4.103 kemunculan), yang jarang dicantumkan secara eksplisit oleh korporasi.
- **Kesesuaian Pengalaman Kerja (*Vertical Mismatch*):**
Ditemukan pola ketidaksesuaian vertikal yang kentara antara profil pencari kerja dan ekspektasi pasar. Volume sebaran kandidat didominasi secara padat oleh pelamar tingkat *Junior* (1–3 tahun pengalaman). Namun, kebutuhan rekrutmen perusahaan terkonsentrasi secara solid pada level *Senior* (5–10 tahun pengalaman) untuk memegang kendali arsitektur sistem yang kompleks. Hal ini memaksa talenta junior berkompetisi pada formasi yang belum sesuai dengan jam terbang mereka.
- **Cakupan dan Relevansi Regulasi SKKNI:**
Standar nasional SKKNI telah memiliki fondasi yang kuat, mencakup 133 unit kompetensi utama pada 5 rumpun jabatan digital prioritas (Programmer, Data Analyst, Data Scientist, Cyber Security, dan Keuangan), dengan profesi Programmer memikul beban standarisasi paling kompleks (37 unit kompetensi). Meskipun memadai sebagai basis data relasional (*ground truth*), dokumen SKKNI masih memiliki keterbatasan dalam mengakomodasi terminologi teknologi mutakhir seperti *framework* AI terapan dan arsitektur *Multi-Cloud* modern secara eksplisit.
- **Keunggulan Sains Model (*A/B Testing*):**
Melalui pengujian eksperimen lintas bahasa (*cross-lingual*), hipotesis nol (H_0) berhasil ditolak. Model Sentence-BERT Multilingual (*Treatment Variant*) terbukti secara empiris mengungguli metode konvensional TF-IDF *Keyword Matching* (*Baseline Control*). Meskipun TF-IDF menghasilkan nilai presisi mutlak (100.00%) karena sifat pencocokan katanya yang kaku, model ini menderita nilai *Recall* yang sangat rendah (45.83%) dengan akurasi 72.91%. Sebaliknya, arsitektur Sentence-BERT mampu menangani kesenjangan bahasa (Inggris-Indonesia) dengan menangkap esensi makna.

7.2 LAMPIRAN

Struktur File :

```
None
Data-Science/
├── dashboard/
│   ├── dashboard.py
│   ├── data_loader.py
│   └── logopelet.png
├── data/
│   ├── raw/
│   │   ├── Dataset_pekerjaan.csv
│   │   ├── all_job_post.csv
│   │   ├── job_roles.csv
│   │   ├── skills_list.csv
│   │   └── training_data.csv
│   └── clean/
│       ├── cleaned_job_5.csv
│       ├── cleaned_skills_list.csv
│       ├── cleaned_training_data.csv
│       ├── data_pekerjaan.csv
│       ├── skill_mapping_dictionary.csv
│       └── skkni_reference_clean.csv
├── dataset/
│   ├── cleaned_job_5.csv
│   ├── cleaned_training_data.csv
│   ├── skill_mapping_dictionary.csv
│   └── skkni_reference_clean.csv
├── notebooks/
│   ├── EDA_1.ipynb
│   ├── EDA_2_final.ipynb
│   ├── ab_testing.ipynb
│   ├── datawrangling_kaggle.ipynb
│   ├── datawrangling_jobstreet.ipynb
│   └── datawrangling_skkni.ipynb
├── Laporan.pdf
├── Data Dictionary.xlsx
├── requirements.txt
└── README.md

# Modul untuk visualisasi antarmuka pengguna
# Script utama untuk menjalankan aplikasi dashboard
# Script untuk membaca dan memproses awal data dashboard
# Aset gambar/logo untuk kebutuhan visual dashboard

# Penyimpanan seluruh dataset proyek
# Dataset mentah sebelum diproses (Data Asli)

# Dataset hasil pembersihan dan siap analisis

# Salinan dataset terpilih (deployment/keperluan khusus)

# Berkas eksperimen dan analisis data (Jupyter Notebook)
# Analisis Data Eksploratif tahap awal
# Analisis Data Eksploratif tahap akhir/final
# Notebook untuk eksperimen dan pengujian A/B
# Pembersihan data yang bersumber dari Kaggle
# Pembersihan data lowongan dari Jobstreet
# Pembersihan datastandar kompetensi SKKNI

# Berisi penjelasan analisis
# Berisi penjelasan dataset yang digunakan untuk modeling
# Daftar dependensi library Python proyek
# Dokumentasi ringkas mengenai proyek dan panduan instalasi
```